

# 刘原宁

LIU YUAN NING

求职意向: Agent 智能体开发工程师

<https://github.com/Bidengone>



24 岁



河北省承德市



15756494780



ll3191125498@163.com



西南民族大学 | 通信工程专业 | 工学学士学位

2021-09-01 至 2026-01-16



## 工作经历

2025.07 - 2026.07

上海聚蜂智擎人工智能技术有限公司

智能体开发工程师

- 负责构建可插拔的文本分类系统以及全链路工程化
- 负责 AI 智能体 (Agent) 应用与大模型落地的研发: 基于 LangChain / LangGraph 设计并开发具备规划记忆、工具调用能力的智能体, 支撑多场景业务需求。
- 负责 RAG 检索链路建设: 完成文档解析、向量化、Milvus 检索与精排, 保证大模型回答有据可依; 负责 DeepSeek 等大模型 API 接入与本地模型 (嵌入/精排/意图分类) 的集成、混合路由与 Prompt 优化, 控制推理成本。
- 负责智能体工程质量与稳定性: 实现状态管理与人工复核闭环 (HitL)、SSE 流式输出、失败重试与降级兜底, 并搭建性能评估体系 (时延 / 成本 / 任务成功率) 持续迭代优化。



## 专业技能

- 机器学习: scikit-learn、Pandas、NumPy; 随机森林、GBDT、FastText 等经典模型与集成策略
- 深度学习: PyTorch; BERT / MacBERT 微调与部署、模型量化 / 蒸馏 / 剪枝
- 大模型应用: LangChain / LangGraph 智能体编排、DeepSeek / OpenAI API、Prompt Engineering
- RAG 与检索: Milvus 向量检索、BGE-M3 Embedding、BGE-Reranker 精排、chunk 切分、文档解析
- Agent 工程: 意图分类与多智能体路由、HitL (interrupt 暂停 / 恢复)、状态机、SSE 流式
- Web 后端: FastAPI 异步开发、RESTful API、JWT 鉴权、PostgreSQL (异步 SQLAlchemy / JSONB)
- 工具链: Git、Docker Compose、pytest、asyncio、jieba / TF-IDF 数据处理



## 项目经历.一

2025.07 - 2026.01

文本智能分类引擎

- 项目描述:** 某新闻资讯平台日均产生数万条 UGC/PGC 短内容, 原有编辑人工分拣模式效率低下、分类标准不一, 导致内容投递延迟严重, 影响用户留存与推荐点击率。该项目是一套可插拔、高准确率、低延迟的文本分类引擎, 直接嵌入线上推荐系统, 覆盖 RF、FastText、MacBERT、Deepseek LLM 四代模型。
- 技术栈:** scikit-learn (RF+GBDT 集成)、jieba 分词、TF-IDF、FastText、PyTorch + MacBERT (ModelScope 微调)、DeepSeek API (OpenAI SDK)、Flask + Blueprint、Streamlit、Docker Compose、pytest、Git
- 核心工作:** 实现四版本递进式方案
  - v1 随机森林 + GBDT 软投票 (jieba→TF-IDF 1-2gram), v2 FastText (字级/词级双路径 + AutoTune 自动调参), v3 MacBERT (16 轮微调, \_max length=32), v4 DeepSeek LLM (零训练、精简 Prompt) 准确率从 82.5% 逐级提升至 95.8%。
  - Flask 应用工厂 + Blueprint 架构, 四版本独立蓝图 / 路由分离 (/api/v1~v4), 统一 JSON 响应格式, 模型可插拔。
  - DockerCompose 双容器部署, Streamlit 前端 (LUMINA 设计), pytest+benchmark 全覆盖。
- 项目成果:** 准确率逐版本递进 (82.5%→95.8%), v3 推理 2ms、v2 4.9ms, 满足实时推荐场景。交付从数据预处理到 Docker 部署的全链路可运行系统, 支持一键训练与一键启动。



## 项目经历.二

2026.01 – 2026.07

基于 Lang Graph 多智能体编排+RAG 的智能助教系统

- ◆ **项目描述**：某职业培训机构日均产生大量学生答疑、作业提交与模拟面试需求，原有教师人工处理模式效率低下、标准不一，导致答疑响应慢、批改分数因人而异、面试人力成本高。该项目是一套可插拔、多智能体、带人工复核闭环的 AI 教学助教平台，覆盖智能问答、试卷批改、模拟面试、简历审查四大教学场景。
- ◆ **技术栈**：LangGraph + LangChain、FastAPI、PostgreSQL、Milvus、BGE-M3 / BGE-Reranker / MiniLM（本地推理）、DeepSeek API、PyMuPDF、Docker Compose、Vue3、pytest
- ◆ **核心工作**：参与设计并实现
  - 多智能体编排：基于LangGraph 构建四个 Agent（智能问答 / 试卷批改 / 简历审查 / 模拟面试），由 Orchestrator 统一调度，支持单 Agent 直达、多 Agent 串联Pipeline（简历审查 → 模拟面试）、意图不明时澄清追问；Agent 图懒加载、统一thread\_id 会话隔离。
  - RAG 检索链路：文档解析 按标题/语义切块（chunk\_size=512、overlap=100） Contextual RAG 生成定位描述 BGE-M3 稠密(1024 维)+稀疏双向量入库 Milvus 混合检索（WeightedRanker 0.7/0.3 + HNSW）召回 Top10 BGE-Reranker CrossEncoder 精排Top3；检索置信度低于0.75 自动降级 Web 搜索兜底，并落入待补充知识库队列形成闭环
  - 意图分类与路由：MiniLM 本地微调二分类（general / specialized，阈值 0.85）+ 规则快判漏斗，先规则后模型省 token；跨 Agent 路由由 LLM 判断，支持问答/批改/简历/面试/多智能体/澄清六类。
  - 试卷批改 + 人工复核闭环：三轨并行批改（规则引擎判客观题、LLM 语义评简答题、LLM 评代码题），简答题每 3 题一组限流并行；低置信度（<0.7）自动标记人工复核，基于 LangGraph interrupt + Command(resume=...) 实现 Human-in-the-loop 暂停/恢复，业务状态机（ai\_processing pending\_review published）与数据库约束对齐。
  - 模拟面试：五阶段状态机（热身 → 技术基础 → 项目深挖 → 反问收尾 → 报告），技术原理 + 项目深挖双轨考察，回答质量四档驱动追问/换题，最终生成五维度雷达图报告。
  - 简历审查：PyMuPDF 双栏解析 → JSON mode 结构化提取 → 六维度（项目深度/技术匹配/表达/结构/量化/可信度）asyncio.gather 并行评分加权。
  - 流式与后端工程：SSE 流式输出（astream\_events 定位节点，token/progress/meta 等事件）；本地模型进程内单例 + 启动并行预热，DeepSeek API 混合路由控成本；JWT 鉴权 + 多租户 tenant\_id 隔离；解决 transformers/FlagEmbedding 版本兼容、Windows 事件循环（阻塞操作丢线程池）等兼容问题。
- ◆ **项目成果**：交付一套端到端可运行的多智能体教学助教平台：四大智能体 + 统一 SSE 入口跑通；试卷批改实现人工复核闭环，教师可在线复核改分并发布；RAG 采用稠密 + 稀疏混合检索与两阶段精排，无结果/低置信度自动兜底；配套知识库构建脚本、数据库 DDL、Milvus 索引初始化与 Docker Compose 基础设施（PostgreSQL / Milvus / MinIO / etc d），支持私有化部署。



## 自我评价

具备大模型应用与智能体（Agent）开发的完整项目经验，从 RAG 检索链路、多智能体编排到人工复核闭环均有实际落地，能独立承担"模型接入 → 业务编排 → 工程交付"全流程工作。

掌握传统机器学习与深度学习基础（文本分类、模型微调、模型压缩），技术栈覆盖 LangChain/LangGraph、FastAPI、Milvus、Docker 等主流工程体系。

从通信工程专业转到 AI 行业，注重工程化思维，学习能力强，对 Agent、RAG 等前沿方向保持持续跟进，乐于把新技术落地为可用的系统。

业余爱好阅读写作，具备逻辑思维与抗压能力，能快速融入团队。希望在 AI 领域持续深入。



网页版 个人简历

<https://bidengone.github.io/resume-3d/>

Personal resume



2026