

刘原宁

LIU YUAN NING

求职意向: Agent 智能体开发工程师

<https://github.com/Bidengone>



简历·网页版



24 岁



河北省承德市



15756494780



ll3191125498@163.com

西南民族大学 | 通信工程专业 | 工学学士学位

2021-09-01 至 2026-01-16



工作经历

2025.07 - 2026.07

上海聚蜂智擎人工智能技术有限公司

智能体开发工程师

- 负责构建可插拔的文本分类系统以及全链路工程化
- 负责 AI 智能体 (Agent) 应用与大模型落地的研发: 基于 LangChain / LangGraph 设计并开发具备规划记忆、工具调用能力的智能体, 支撑多场景业务需求。
- 负责 RAG 检索链路建设: 完成文档解析、向量化、Milvus 检索与精排, 保证大模型回答有据可依; 负责 DeepSeek 等大模型 API 接入与本地模型 (嵌入/精排/意图分类) 的集成、混合路由与 Prompt 优化, 控制推理成本。
- 负责智能体工程质量与稳定性: 实现状态管理与人工复核闭环 (HitL)、SSE 流式输出、失败重试与降级兜底, 并搭建性能评估体系 (时延 / 成本 / 任务成功率) 持续迭代优化。



专业技能

- 机器学习: scikit-learn、Pandas、NumPy; 随机森林、GBDT、FastText 等经典模型与集成策略
- 深度学习: PyTorch; BERT / MacBERT 微调与部署、模型量化 / 蒸馏 / 剪枝
- 大模型应用: LangChain / LangGraph 智能体编排、DeepSeek / OpenAI API、Prompt Engineering
- RAG 与检索: Milvus 向量检索、BGE-M3 Embedding、BGE-Reranker 精排、chunk 切分、文档解析
- Agent 工程: 意图分类与多智能体路由、HitL (interrupt 暂停 / 恢复)、状态机、SSE 流式
- Web 后端: FastAPI 异步开发、RESTful API、JWT 鉴权、PostgreSQL (异步 SQLAlchemy / JSONB)
- 工具链: Git、Docker Compose、pytest、asyncio、jieba / TF-IDF 数据处理



项目经历.一

2025.07 - 2026.01

文本智能分类引擎

- 项目描述:** 某新闻资讯平台日均产生数万条 UGC/PGC 短内容, 原有编辑人工分拣模式效率低下、分类标准不一, 导致内容投递延迟严重, 影响用户留存与推荐点击率。该项目是一套可插拔、高准确率、低延迟的文本分类引擎, 直接嵌入线上推荐系统, 覆盖 RF、FastText、MacBERT、Deepseek LLM 四代模型。
- 技术栈:** scikit-learn (RF+GBDT 集成)、jieba 分词、TF-IDF、FastText、PyTorch + MacBERT (ModelScope 微调)、DeepSeek API (OpenAI SDK)、Flask + Blueprint、Streamlit、Docker Compose、pytest、Git
- 核心工作:** 设计四版本递进式方案
 - v1 随机森林 + GBDT 软投票 (jieba→TF-IDF 1-2gram), v2 FastText (字级/词级双路径 + AutoTune 自动调参), v3 MacBERT (16 轮微调, max_length=32), v4 DeepSeek LLM (零训练、精简 Prompt), 准确率从 82.5% 逐级提升至 95.8%。
 - Flask 应用工厂 + Blueprint 架构, 四版本独立蓝图 / 路由分离 (/api/v1~v4), 统一 JSON 响应格式, 模型可插拔。
 - Docker Compose 双容器部署, Streamlit 前端 (LUMINA 设计), pytest + benchmark 全覆盖。
- 项目成果:** 准确率逐版本递进 (82.5%→95.8%), v3 推理 2ms、v2 4.9ms, 满足实时推荐场景。交付从数据预处理到 Docker 部署的全链路可运行系统, 支持一键训练与一键启动。



项目经历.二

2026.01 – 2026.07

基于 Lang Graph 多智能体编排+RAG 的智能助教系统

◆ **项目描述**：某职业培训机构日均产生大量学生答疑、作业提交与模拟面试需求，原有教师人工处理模式效率低下、标准不一，导致答疑响应慢、批改分数因人而异、面试人力成本高。该项目是一套可插拔、多智能体、带人工复核闭环的 AI 教学助教平台，覆盖智能问答、试卷批改、模拟面试、简历审查四大教学场景。

◆ **技术栈**：LangGraph + LangChain、FastAPI、PostgreSQL、Milvus、BGE-M3 / BGE-Reranker / MiniLM（本地推理）、DeepSeek API、PyMuPDF、Docker Compose、Vue3、pytest

◆ **核心工作**：设计四大智能体 + 统一入口的编排式方案

-智能问答走 RAG 链路（文档解析 → chunk 切分 → BGE-M3 向量入库 → Milvus 召回 Top30 → Reranker 精排 Top5），意图分类用 MiniLM 本地模型，检索与分类全程不出内网；无结果/低置信度转人工兜底。

-试卷批改基于 LangGraph interrupt + AsyncPostgresSaver 实现 Human-in-the-loop：AI 按评分点初（客观题代码比对、主观题评分点拼接 Prompt + temperature=0）→ 汇总后暂停 → 教师复核改分 → 发布成绩，状态机与数据库约束逐字对齐，跨请求、跨进程可恢复。

-模拟面试采用五阶段状态机多轮对话，动态追问 + 评分报告；简历审查实现 PDF 解析 → 结构化提取 → 六维度并行评分（asyncio.gather）→ 问题清单与建议。

-编排器按意图路由四智能体，统一对话入口 SSE 流式输出（chunk/done/error 事件），session_id 支撑多轮上下文。

-本地模型（BGE-M3/Reranker/MiniLM）Docker 部署 + DeepSeek API 混合路由控制成本；解决 transformers/FlagEmbedding 版本兼容、Windows 事件循环兼容问题。

◆ **项目成果**：四大智能体 + 统一入口端到端跑通，批改-复核闭环成功率 100%（示例），检索 Recall@5 由纯向量 0.70 提升至 0.85（示例），主观题评分方差由 ± 8 收敛至 ± 1 （示例）；交付从知识库构建、智能体编排到 Docker Compose 部署的全链路可运行系统，支持私有化部署与一键启动。



自我评价

具备大模型应用与智能体（Agent）开发的完整项目经验，从 RAG 检索链路、多智能体编排到人工复核闭环均有实际落地，能独立承担“模型接入 → 业务编排 → 工程交付”全流程工作。

掌握传统机器学习与深度学习基础（文本分类、模型微调、模型压缩），技术栈覆盖 LangChain/LangGraph、FastAPI、Milvus、Docker 等主流工程体系。

从通信工程专业转到 AI 行业，注重工程化思维，学习能力强，对 Agent、RAG 等前沿方向保持持续跟进，乐于把新技术落地为可用的系统。

业余爱好阅读写作，具备逻辑思维与抗压能力，能快速融入团队。希望在 AI 领域持续深入。